



**ESCOLA
SUPERIOR
DE TECNOLOGIA
E GESTÃO**

Lakehouse para Análise Clínica

TECNOLOGIAS ESCALÁVEIS PARA ANÁLISE DE DADOS

MESTRADO EM ENGENHARIA INFORMÁTICA

Grupo 7

DIOGO PEREIRA – 8200594

DUARTE SAMPAIO – 8190553

HUGO GUIMARÃES – 8220337

NUNO SILVA – 8180393

3 DE JUNHO DE 2026

Conteúdo

1	Introdução	2
1.1	Contextualização e Tema do Projeto	2
1.2	Objetivos do Trabalho	2
1.3	Estrutura do Relatório	2
2	Definição do Problema	4
2.1	Problema a Resolver	4
2.2	Produtos de Dados	4
3	Arquitetura do Lakehouse	6
3.1	Arquitetura Medalhão	6
3.2	Orquestração de Pipelines	7
4	Governança e Garantia de Qualidade	8
4.1	Padrão de Data Contracts	8
4.2	Implementação do Quality Gate	8
4.3	Garantia de Idempotência e Operações de <i>Upsert</i>	8
4.4	Estratégia de Quarentena	9
4.5	Otimização Analítica e Processamento Escalonável	9
5	Visualização dos Dados	10
5.1	Saúde e Qualidade dos Sensores	10
5.2	Pré. vs. Pós Operação	10
5.3	Volatilidade dos Sinais Vitais	11
5.4	Predições para Cuidados Intensivos	13

1 Introdução

1.1 Contextualização e Tema do Projeto

Na atualidade, as instituições de saúde geram volumes massivos de dados por cada caso cirúrgico, que frequentemente acabam por permanecer isolados em diferentes silos. Este projeto desenvolve-se em torno da Empresa Y, uma organização de engenharia de dados focada no setor da saúde, que atua no domínio perioperatório com o objetivo de modernizar a infraestrutura de dados de grandes redes hospitalares.

A plataforma integra três fontes independentes: informação clínica, parâmetros hemodinâmicos e resultados laboratoriais. Contudo, a análise destes dados esbarra em sérios problemas de qualidade, nomeadamente ruído e artefactos nos sinais vitais de alta frequência, bem como timestamps assíncronos e valores nulos nos exames laboratoriais. Para resolver esta fragmentação, propõe-se a implementação de uma arquitetura Lakehouse moderna (assente em MinIO, Apache Iceberg, Trino e Flyte). Esta solução ingere e processa os dados através das camadas Bronze, Silver e Gold, garantindo a qualidade necessária para suportar modelagem preditiva e tomada de decisão.

1.2 Objetivos do Trabalho

O objetivo central deste trabalho prático é simular de forma realista o ciclo de vida de construção e operação de uma plataforma analítica escalável orientada a produtos de dados. Para tal, desenhou-se uma solução end-to-end que aplica os conceitos de data engineering e machine learning, assegurando a separação entre computação e armazenamento.

O projeto visa implementar pipelines orquestrados de forma reproduzível e tolerante a falhas, aplicar estratégias de otimização no processamento dos dados e garantir a qualidade da informação servida através da definição de contratos de dados rigorosos.

1.3 Estrutura do Relatório

Para além desta secção introdutória, o presente relatório encontra-se estruturado em cinco capítulos adicionais:

- **Capítulo 2 - Definição do Problema:** Detalha os desafios inerentes aos dados médicos de alta frequência e especifica os produtos de dados propostos como solução.

- **Capítulo 3 - Arquitetura do Lakehouse:** Apresenta a *stack* tecnológica utilizada, o modelo *Medallion* (Bronze, Silver e Gold) e a forma como os *workflows* foram orquestrados no Flyte.
- **Capítulo 4 - Governança e Garantia de Qualidade:** Explora a implementação de Contratos de Dados (Data Contracts) e a estratégia de quarentena (*Dead Letter Queue*) para assegurar a fiabilidade da informação.
- **Capítulo 5 - Visualização de Dados:** Descreve o consumo analítico das tabelas Gold via motor SQL e a sua consequente visualização em *dashboards* clínicos e operacionais no Grafana.

2 Definição do Problema

2.1 Problema a Resolver

A monitorização contínua em ambiente perioperatório (recorrendo ao VitalDB) gera um fluxo de dados de alta velocidade (frequentemente com múltiplos registos por segundo). O principal problema reside na extrema suscetibilidade destes sensores a artefactos mecânicos (movimentos do paciente, desconexão de cabos) e eletrónicos, resultando em falsos positivos, dados ausentes e flutuações irreais (ruído). Adicionalmente, o cruzamento deste fluxo contínuo com dados pontuais assíncronos (como exames laboratoriais) cria desafios complexos de alinhamento temporal e integração analítica, impossibilitando uma tomada de decisão médica fiável em tempo real se a informação não for devidamente validada e contextualizada.

2.2 Produtos de Dados

Para dar resposta às necessidades analíticas e operacionais do hospital descritas na secção anterior, a arquitetura disponibiliza quatro *Data Products* distintos na camada Gold:

- **Qualidade e Janela de Visualização dos Sinais Vitais:** Converte os dados da camada silver e gera agregações por janelas temporais para monitorizar a qualidade dos sensores e análise clínica exploratória.
 - *Pergunta Analítica:* Qual é a disponibilidade dos sensores ao longo da cirurgia e qual o comportamento médio dos sinais em janelas temporais fixas?
 - *Consumidor:* *Dashboards* de monitorização clínica e auditoria da qualidade dos dados.
- **Avaliação de Impacto Laboratorial (Pré vs. Pós-Operatório):** Combina os resultados laboratoriais com o histórico clínico e demográfico dos pacientes para avaliar a variância bioquímica e o desgaste fisiológico decorrentes do stress cirúrgico.
 - *Pergunta Analítica:* Qual a magnitude da variação dos marcadores bioquímicos críticos no período pós-operatório imediato, estratificada por especialidade médica e género?

- *Consumidor: Dashboard* interativo de suporte à decisão clínica e executiva (desenvolvido em Streamlit), focado na monitorização e exploração visual de tendências populacionais.
- **Registo de Qualidade do Sensor e Anomalias de Dados:** Um produto focado na fiabilidade da infraestrutura. Avalia a qualidade do equipamento em tempo real, impondo contratos de dados rigorosos e fornecendo uma classificação final de saúde (*Health Grade*) para cada dispositivo.
 - *Métricas:* Taxas de nulos na janela ativa, deteção de anomalias temporais (sinais congelados e picos de ruído), incidência de falhas de *hardware* e desvios morfológicos entre sensores paralelos (*drift*).
 - *Consumidor:* Engenheiros de dados (monitorização do *pipeline*) e equipa de manutenção hospitalar (manutenção preditiva).
- **Previsor de Alocação de UCI Pós-Operatória:** Produto que alimenta um modelo de *Machine Learning* supervisionado.
 - *Pergunta Analítica:* Qual a probabilidade de um paciente necessitar de admissão imediata na Unidade de Cuidados Intensivos (UCI) e qual o seu tempo estimado de recuperação?
 - *Consumidor:* Administração hospitalar para pré-alocação de recursos críticos e o modelo treinado rastreado via MLFlow.

3 Arquitetura do Lakehouse

3.1 Arquitetura Medalhão

Para garantir a fiabilidade, qualidade e rastreabilidade dos dados clínicos, a arquitetura de processamento adota o Modelo Medalhão (*Medallion Architecture*). Este padrão de *design* estrutura, representado na Figura 1, divide o *Data Lakehouse* em três camadas lógicas de refinamento progressivo:




Figura 1: Representação Gráfica da Arquitetura Medalhão

- **Camada *Bronze* (Raw):** Atua como a zona de aterragem dos dados. Armazena a informação em estado bruto e imutável, preservando o histórico exato gerado pelos sistemas de origem hospitalar (registos de admissão, resultados laboratoriais e demografia). Os dados csv, para entrarem nesta camada, primeiro precisam de ser convertidos para o formato *parquet* e *iceberg*.
- **Camada *Silver* (Cleansed):** Focada na higienização e conformidade. Nesta camada, os dados brutos são filtrados, padronizados e cruzados. Registos inválidos são tratados e as entidades clínicas são unidas, estabelecendo uma base de dados fiável e relacional (ex: associação do perfil do paciente aos seus exames pré e pós-operatórios).

- **Camada *Gold* (Curated):** A camada de consumo analítico. Contém dados altamente refinados e agregados, modelados especificamente para responder às necessidades de negócio. É aqui que reside as tabelas finais, que fornece as métricas pré-calculadas diretamente nos *dashboards*, garantindo máxima performance de leitura.

3.2 Orquestração de Pipelines

A automatização e gestão dos fluxos de dados (*data pipelines*) são asseguradas pelo **Flyte**, uma plataforma de orquestração distribuída e tolerante a falhas. O Flyte, embora permita estruturar a lógica de processamento através de Grafos Acíclicos Dirigidos (DAGs), foi impossível executar em modo *Remote*, funcionando apenas em modo *Local* o que, embora constrangedor, é perfeitamente funcional.

Nesta solução, o *Orquestrator* é responsável por coordenar a transição da informação através do Modelo Medalhão. Ele garante que as tarefas de ingestão (*Bronze*), higienização e cruzamento relacional (*Silver*) e, finalmente, a agregação de métricas clínicas (*Gold*) são executadas com a precedência correta. O uso do Flyte assegura não só a reprodutibilidade dos *workflows*, mas também a robustez do sistema, permitindo a monitorização contínua e a reexecução isolada de tarefas em caso de falhas na infraestrutura.

4 Governança e Garantia de Qualidade

4.1 Padrão de Data Contracts

Para garantir a fiabilidade da plataforma, adotou-se uma abordagem baseada em *Data Contracts*, seguindo as especificações do *Open Data Contract Standard* (ODCS). Em vez de embutir validações no código, a estrutura, semântica e regras de negócio de cada tabela foram colocadas em ficheiros yaml. Estes contratos definem a tipagem esperada e restrições críticas (por exemplo, `age BETWEEN 0 AND 120` na tabela de demografia ou `no_nulls(case_id, time)` nos sinais vitais), atuando simultaneamente como documentação e especificação técnica para os consumidores de cada *Data Product*.

4.2 Implementação do Quality Gate

Para forçar o cumprimento dos contratos, desenvolveu-se um componente de *Quality Gate* integrado diretamente no Flyte. Este avaliador em Python intercepta os *DataFrames* antes da persistência dos mesmos no Lakehouse. Lendo o ficheiro YAML correspondente, traduz as regras em *strings* para testes (via Pandas/PyArrow). O componente funciona sob o padrão arquitetural de *Circuit Breaker*: caso os dados apresentem qualquer violação de integridade face ao contrato, a *task* falha de imediato e a transação de escrita na tabela Apache Iceberg é abortada, garantindo que as camadas Silver e Gold permanecem limpas.

4.3 Garantia de Idempotência e Operações de *Upsert*

Para evitar duplicações e garantir consistência em reexecuções, implementou-se um mecanismo de idempotência focado em *Upserts* no *workflow* bronze dos pacientes. O algoritmo cruza o novo lote com a tabela Apache Iceberg via chaves primárias (ex: `caseid`, `subjectid`). Metadados técnicos (como `ingest_time`) são ignorados na comparação para impedir atualizações causadas apenas por novos carimbos temporais. Após isolar inserções inéditas (*Insert*) e detetar reais variações clínicas (*Update*), o *DataFrame* final é gravado numa transação ACID única (via *overwrite*). Isto assegura que o *Lakehouse* mantém um estado determinístico, preservando a auditoria das alterações nos *logs* do orquestrador.

4.4 Estratégia de Quarentena

A gestão de dados anómalos ou ruidosos (tais como falhas de hardware, valores impossíveis ou identificadores inválidos) foi implementada com base no padrão *Dead Letter Queue* (DLQ). Na camada Silver, a validação e separação dos dados são realizadas em simultâneo: os registos válidos progridem para as tabelas limpas (ex: `vitals_clean`), enquanto os registos que falham as regras de negócio são isolados em tabelas dedicadas (ex: `vitals_quarantine`). Estas tabelas de quarentena retêm os dados originais acompanhados de uma nova coluna `error_reason`, permitindo a auditoria contínua, o realimentar de *dashboards* de manutenção técnica e a eventual re-ingestão, sem comprometer a disponibilidade dos dados saudáveis.

4.5 Otimização Analítica e Processamento Escalonável

Embora não tenha sido o principal foco do projeto, foram aplicados princípios de processamento escalonável (*Scalable Processing*) e otimização na camada de *Serving* (Trino/Grafana). O objetivo foi assegurar que o sistema cumpre os *Service Level Objectives* (SLOs) de performance, minimizando o custo por execução (*cost per run*) perante volumes crescentes de dados.

Um exemplo prático desta aplicação encontra-se na consulta SQL desenvolvida para alimentar o gráfico de "Distribuição de Tipos de Falha por Marca de Equipamento" no *dashboard* de manutenção:

```
1  WITH erros_agrupados AS (  
2      SELECT equipment_brand, error_reason, CAST(SUM(failure_count) AS  
        DOUBLE) AS total_falhas  
3      FROM iceberg.gold.hardware_failures_summary  
4      WHERE equipment_brand IN (${marca:singlequote})  
5      GROUP BY equipment_brand, error_reason  
6  )  
7  SELECT  
8      equipment_brand, error_reason, total_falhas,  
9      ROUND((total_falhas / SUM(total_falhas) OVER (PARTITION BY  
        equipment_brand)) * 100, 2) AS pct_erro  
10 FROM erros_agrupados  
11 ORDER BY equipment_brand, pct_erro DESC
```

Excerto 1: Query SQL para Distribuição de Tipos de Falha por Marca de Equipamento

Esta consulta é otimizada através dos seguintes mecanismos:

- ***Predicate Pushdown* Prévio:** O filtro `WHERE equipment_brand IN (...)` é aplicado logo na *Common Table Expression* (CTE) inicial, reduzindo drasticamente o volume de dados a ler da tabela Iceberg antes de qualquer agregação pesada (*Filter Pushdown*).
- **Gestão Eficiente de *Shuffle*:** Em vez de calcular a percentagem total de falhas, forçando um cruzamento de dados (*Join*) com uma tabela agregada externa, a consulta utiliza uma *Window Function* (`SUM(...) OVER(PARTITION BY...)`). O uso de agregações em janela não precisa de grandes operações para movimentar os dados (*shuffle-heavy*), limitando o processamento à partição específica em memória.

5 Visualização dos Dados

5.1 Saúde e Qualidade dos Sensores

O *dashboard* de Qualidade dos Sensores foi construído no Grafana e liga-se diretamente à camada *Gold* do *Lakehouse* via motor SQL (Trino). A sua principal função é traduzir as milhões de leituras e anomalias filtradas num diagnóstico visual e acionável para a equipa de manutenção hospitalar. Através de *scorecards* agregados, é possível monitorizar a percentagem de equipamentos com funcionamento "Excelente" e "Aceitável", bem como identificar rapidamente taxas de erro e problemas de conectividade.

A visão detalhada em formato de tabela permite à equipa técnica isolar rapidamente os componentes que apresentam "Falha Crítica" ou estado "Degradado". A avaliação é suportada por métricas concretas processadas ao segundo, como o número de picos de ruído, sinais congelados e a duração real da utilização do sensor. Esta abordagem transforma a resposta a avarias num processo de manutenção preditiva, indicando aos técnicos exatamente qual o caso clínico e o equipamento que necessitam de intervenção ou recalibração antes de comprometerem futuras cirurgias.

5.2 Pré. vs. Pós Operação

O *Dashboard* clínico pré e pós operatório permite medir o impacto e o cansaço causados pela cirurgia. Com base nos dados de todos os pacientes, o ecrã usa um gráfico *Lollipop*




Figura 2: Dashboard Grafana de Saúde e Qualidade dos Sensores

para ajudar a equipa médica a ver rapidamente o que mudou em dezenas de análises ao sangue. Esta imagem mostra de forma clara o que desceu (linhas para a esquerda a rosa, ex: AMMO) e o que subiu ou se manteve (linhas para a direita a azul, ex: CCR ou PO2) logo a seguir à operação.

Além disso, a plataforma separa os resultados por género, usando gráficos de barras para mostrar as diferenças entre homens e mulheres. Este detalhe revela problemas que ficam escondidos quando olhamos apenas para a média geral. Por exemplo, mostra que a queda do valor de AMMO é muito mais grave nos homens.

Com a ajuda de filtros por especialidade médica e por indicador clínico, o painel transforma dados difíceis em informação clara e útil. Isto ajuda os médicos a planear melhor a recuperação de cada paciente.

5.3 Volatilidade dos Sinais Vitais

O dashboard desenvolvido tem como objetivo apoiar a interpretação dos sinais vitais recolhidos durante o procedimento cirúrgico, permitindo comparar o sinal bruto com o sinal suavizado e observar o efeito do processamento aplicado. A interface foi organizada em torno de filtros de cirurgia e sensor, o que possibilita ao utilizador selecionar rapidamente o contexto clínico pretendido e analisar a respetiva evolução temporal. Para melhorar a leitura dos resultados, o dashboard inclui ainda informação descritiva sobre cada sensor, como o parâmetro medido, a unidade de medida e a marca do equipamento, tornando a análise mais intuitiva e menos dependente de identificadores técnicos.

A página principal do relatório apresenta, lado a lado, o sinal antes e depois da suavização, facilitando a comparação entre a variabilidade original e a tendência subjacente




Figura 3: Dashboard Streamlit Pré e Pós Operatório

após tratamento dos dados. Esta abordagem permite evidenciar a utilidade da suavização na redução de ruído e na interpretação clínica dos sinais. Além disso, a estrutura do dashboard foi pensada para ser interativo e orientada ao utilizador final, permitindo explorar os dados por cirurgia e por sensor sem necessidade de recorrer a consultas à base de dados. Desta forma, o dashboard transforma dados operacionais em informação visual mais clara, apoiando a análise exploratória e a comunicação dos resultados.




Figura 4: Dashboard PowerBI de Volatilidade dos Sinais Vitais

```
Running Execution on local.
Fetched features for caseid=1: 1 row(s)
Best regression model: RandomForestRegressor RMSE=2.720
Best classification model: RandomForestClassifier AUC=0.884
{
  "caseid": "1",
  "actual_icu_days": 0.0,
  "regression": {
    "model": "models:/icu_RandomForestRegressor/latest",
    "predicted_icu_days": 0.0
  },
  "classification": {
    "model": "models:/icu_RandomForestClassifier/latest",
    "predicted_needs_icu": false,
    "verdict": "No ICU needed"
  }
}
```

Figura 5: Output da Consola da Predição

5.4 Predições para Cuidados Intensivos

O workflow de inferência do ICU Days Predictor foi implementado como uma pipeline do Flyte composto por quatro tarefas. Dado um ID relativo a um caso de paciente, a tarefa *fetch_case_features* reconstrói o mesmo vetor de características utilizado durante o treino. Consultando a camada Silver, esta junta os dados demográficos do paciente (idade, sexo, IMC, score ASA) com o contexto cirúrgico (departamento, tipo de operação, abordagem, tipo de anestesia) e transforma os resultados laboratoriais pré-operatórios (hemoglobina, plaquetas, leucócitos, glicose, creatinina, albumina) numa única linha plana (flat row).

As tarefas *find_best_regression_model* e *find_best_classification_model* consultam o servidor do MLflow, classificando todas as execuções registadas na experiência *ICU_Days_Regression* pelo menor RMSE, e na experiência *ICU_Days_Classification* pelo maior AUC-ROC, devolvendo o URI do registo de modelos do vencedor.

Por último, a tarefa *run_predictions* carrega ambos os modelos a partir do MLflow Model Registry, aplica-os à linha de características e devolve um resultado estruturado em JSON contendo o número previsto de dias no UCI (regressão), o veredicto binário de admissão no UCI (classificação) e o valor real para comparação. Este design garante que a seleção do modelo seja sempre orientada por dados e reflita automaticamente qualquer reajuste futuro, sem a necessidade de atualizações manuais no pipeline de inferência.